

Bankify Analytics Lab

Guía del modelo de predicción de mora · Variables, métricas y gráficas

1. Variables originales del dataset

El dataset proviene de tarjetas de crédito de clientes en Taiwán. Cada fila representa un cliente y su historial de los últimos 6 meses (abril a septiembre). La moneda es el dólar taiwanés (NT\$).

Variable	Tipo	Significado	Valores permitidos
LIMIT_BAL	Continuo	Límite de crédito otorgado al cliente. A mayor cupo, mayor confianza crediticia inicial del banco.	Número positivo (NT\$)
SEX	Nominal	Género del titular de la cuenta.	1 = Masculino 2 = Femenino
EDUCATION	Ordinal	Nivel educativo máximo alcanzado.	1 = Posgrado 2 = Universidad 3 = Bachillerato 4 = Otros
MARRIAGE	Nominal	Estado civil del cliente.	1 = Casado 2 = Soltero 3 = Otros / Divorciado
PAY_0 a PAY_6	Ordinal	Estado de pago mensual: PAY_0 = septiembre, PAY_6 = abril. Indica cuántos meses de atraso acumuló ese mes.	-2 = Sin consumo -1 = Al día 0 = Pago mínimo / rotativo 1 a 9 = Meses de atraso
PAY_AMT1 a PAY_AMT6	Continuo	Monto abonado por el cliente cada mes de los últimos 6 meses.	Número ≥ 0 (NT\$)
DEFAULT	Binario (variable objetivo)	Si el cliente cayó en mora el mes siguiente. Es lo que el modelo aprende a predecir.	0 = No cayó en mora 1 = Sí cayó en mora

Variables eliminadas del modelo

Variable	Razón de eliminación
ID	Solo es un identificador único; no aporta ninguna información predictiva.
AGE	Baja relevancia predictiva según el análisis de importancia de variables.
BILL_AMT1 a BILL_AMT6	Alta correlación entre sí (multicolinealidad elevada). El modelo ya captura el comportamiento de facturación indirectamente a través del historial PAY.

2. Features construidas para el modelo

Las 12 columnas originales PAY y PAY_AMT están muy correlacionadas entre sí. En lugar de usarlas directamente, se calculan 4 features que capturan la información más relevante con menos redundancia. A continuación se aplica StandardScaler (centrado y escalado) a todas las variables numéricas.

Feature	Cómo se calcula	Qué captura
PAY_max	Máximo de PAY_0, PAY_2, PAY_3, PAY_4, PAY_5, PAY_6	El peor momento crediticio del cliente en 6 meses. Si en algún mes acumuló 3 meses de atraso, este valor es 3. Es el predictor más fuerte de mora futura.
PAY_mean	Promedio de los 6 valores PAY	Si el patrón de retraso es crónico o fue algo puntual. Un valor alto sostenido indica riesgo estructural; un valor bajo con un pico puntual sugiere incidente aislado.
PAY_n_atrasos	Conteo de meses con PAY > 0	Cuántos de los 6 meses tuvo algún atraso. Un cliente con 5 de 6 meses en atraso es muy distinto a uno con solo 1 de 6.
PAY_AMT_total	Suma de PAY_AMT1 a PAY_AMT6	Capacidad y voluntad de pago total en 6 meses. Quien abona más tiene menor riesgo. Complementa el historial PAY: un cliente puede estar atrasado pero seguir abonando.

Las variables categóricas *SEX*, *EDUCATION* y *MARRIAGE* se convierten en columnas numéricas mediante one-hot encoding (*drop_first=True* para evitar multicolinealidad perfecta).

3. Clasificador y entrenamiento

Parámetro	Valor	Qué significa
Algoritmo	Árbol de Decisión	Clasifica mediante reglas IF-THEN encadenadas. Explicable, visualizable y no requiere supuestos sobre la distribución de los datos.
max_depth	6	El árbol no puede tener más de 6 niveles de profundidad. Controla el sobreajuste: un árbol muy profundo memoriza el entrenamiento pero falla en datos nuevos.
criterion	entropy	Usa entropía de información para elegir el mejor split en cada nodo. Mide cuánto reduce la incertidumbre cada variable candidata.
class_weight	balanced	Compensa el desbalance de clases (~22% mora vs 78% sin mora). Da más peso a los ejemplos de mora para que el modelo no los ignore.
División de datos	80% entrenamiento 20% prueba (estratificado)	El 20% de prueba nunca es visto por el modelo durante el entrenamiento. La estratificación garantiza que ambas particiones conserven la misma proporción de mora.
Validación	Validación cruzada 5-fold	El dataset de entrenamiento se divide en 5 partes; el modelo se entrena 5 veces usando 4 partes y validando con la quinta. Estima la varianza del desempeño.
Optimización	Optuna	Busca automáticamente la mejor combinación de hiperparámetros (<i>max_depth</i> , <i>min_samples_leaf</i> , <i>min_samples_split</i> , etc.) mediante muestreo bayesiano.

4. Métricas mostradas en pantalla

Estas métricas se calculan sobre el 20% de datos que el modelo nunca vio durante el entrenamiento (conjunto de prueba).

Métrica	Qué mide	Cómo interpretarla
Exactitud (Accuracy)	Porcentaje de predicciones correctas sobre el total de clientes.	Ej: 82% = acertó 82 de cada 100. Útil pero engañosa con clases desbalanceadas: un modelo que siempre predice 'sin mora' obtendría ~78% de exactitud sin detectar ningún moroso.
Precisión	De todos los clientes marcados como 'va a caer en mora', qué porcentaje realmente cayó.	Alta precisión = pocas falsas alarmas. Si es 60%, de cada 10 alertas generadas, 4 corresponden a clientes que sí pagaron.
Exhaustividad (Recall)	De todos los clientes que sí cayeron en mora, cuántos detectó el modelo.	Alto recall = el modelo no deja escapar casos reales de mora. Es la métrica más crítica en contexto de riesgo crediticio: un moroso no detectado representa una pérdida real.
F1-Score	Media armónica entre Precisión y Recall.	Útil cuando importan ambas: no generar falsas alarmas pero tampoco dejar pasar morosos. Valor entre 0 y 1; mayor es mejor.
AUC-ROC	Área bajo la curva ROC. Mide la capacidad discriminativa global del modelo.	0.5 = modelo aleatorio (línea diagonal). 1.0 = modelo perfecto. El modelo actual supera el baseline. Es independiente del umbral de decisión elegido.

5. Matriz de confusión

Tabla 2x2 que muestra los 4 posibles resultados de una clasificación binaria. Las celdas de la diagonal principal (TN y TP) son aciertos; las otras dos son errores.

	Predicho: Sin mora	Predicho: Mora
Real: Sin mora	TN — Verdadero Negativo Correcto: dijo 'sin mora' y tenía razón.	FP — Falso Positivo Falsa alarma: dijo 'mora' pero el cliente sí pagó.
Real: Mora	FN — Falso Negativo Caso perdido: dijo 'sin mora' pero el cliente no pagó. Es el peor error en contexto de riesgo crediticio.	TP — Verdadero Positivo Correcto: dijo 'mora' y el cliente sí cayó en mora.

6. Gráficas de la aplicación

Gráfica	Dónde aparece	Qué muestra	Cómo leerla
Curva ROC	Sección resultados del modelo	Cómo varía la capacidad del modelo al ajustar el umbral de decisión.	Eje X: tasa de falsos positivos (falsas alarmas generadas). Eje Y: tasa de verdaderos positivos (morosos reales detectados). La línea diagonal es el baseline de un modelo aleatorio (AUC 0.5). El punto rojo marca el umbral óptimo calculado con el Índice de Youden: el mejor balance entre capturar morosos y minimizar falsas alarmas.

Gráfica	Dónde aparece	Qué muestra	Cómo leerla
Importancia de variables (SHAP)	Sección resultados y predicción individual	Qué variables pesaron más en las decisiones del modelo.	Barras horizontales ordenadas de mayor a menor impacto promedio. SHAP (SHapley Additive exPlanations) mide cuánto empujó cada variable la predicción hacia mora o hacia no mora. Las barras más largas son las variables más influyentes. PAY_max y PAY_n_atrasos suelen dominar.
Árbol de decisión (profundidad 3)	Sección explicabilidad	Las reglas IF-THEN que el modelo aplica para clasificar un cliente.	Cada nodo interior muestra la variable usada y el umbral de corte (ej: $\text{PAY_max} \leq 0.5$). Las hojas muestran la clase predicha y cuántos clientes del entrenamiento caen en esa rama. Colores más intensos = clase más dominante en ese nodo.
Tarjeta de predicción individual	Paso de simulación	El resultado del modelo para los datos ingresados por el usuario.	Muestra: etiqueta ('Alta/Baja probabilidad de mora'), porcentaje de confianza (predict_proba), barra de progreso visual y el nombre del modelo usado.
Dashboard EDA (8 gráficos)	Sección exploración de datos	Distribuciones y relaciones entre variables antes de modelar.	1) Distribución de DEFAULT: desbalance ~22%/78%. 2) Distribución de LIMIT_BAL: mayoría concentrada en cupos bajos. 3) LIMIT_BAL vs DEFAULT: morosos tienden a tener cupos menores. 4) Edad vs DEFAULT. 5) Cupo promedio por edad/DEFAULT. 6-7) Heatmap de correlaciones en dos formatos. 8) Análisis multivariado simultáneo.
Gráfico 3D de comentarios	Sección comentarios (paso 6)	Proyección UMAP de los comentarios de todos los participantes en el espacio semántico.	Comentarios con significado similar quedan cercanos en el espacio 3D. Colores = tipo de comentario (dataset, analytics, prediction). Puntos grandes y opacos = sesión actual. Puntos pequeños y tenues = otras sesiones. No es parte del modelo de mora.

7. Puntaje de predicción individual

Cuando se simula un cliente específico ingresando sus datos, el modelo produce los siguientes elementos en pantalla:

Valor mostrado	Significado
Probabilidad de mora (%)	Qué tan seguro está el modelo de que ese cliente caerá en mora. Ejemplo: 73% = riesgo alto. Proviene de predict_proba del árbol de decisión, que estima la proporción de ejemplos de mora en la hoja correspondiente.
Etiqueta	'Alta probabilidad de mora' o 'Baja probabilidad de mora' según si la probabilidad supera el umbral óptimo calculado con el Índice de Youden. Este umbral no es necesariamente 50%.
Barra de progreso	Representación visual del porcentaje de probabilidad. Más llena = mayor riesgo percibido por el modelo.

Valor mostrado	Significado
Top 3 variables (SHAP local)	Las 3 variables que más influyeron en la predicción de ese cliente específico, no del modelo en general. Cada cliente puede tener factores determinantes distintos: para uno puede ser PAY_max, para otro PAY_AMT_total.
Explicación pedagógica	Texto en lenguaje natural que resume: etiqueta, probabilidad estimada, top 3 variables locales y su interpretación en contexto crediticio. Generado por el agente de explicación pedagógica usando el modelo de lenguaje.